https://gemini.google.com/app/b4aea1f471fa9063

应聘大模型调优与工程落地岗位，结合你当前在本地 RAG 项目中实践的技术栈（如 PyTorch、Transformers、Qwen、KV Cache 优化等），核心技能经验可拆解为以下四个维度：

1. **核心理论与算法架构**
   - **大模型架构原理**：深入理解 Transformer 架构中 Self-Attention、KV Cache、自回归生成及位置编码等底层数学原理。
   - **开源模型生态**：熟悉主流开源大模型（如项目中用到的 Qwen2.5）的权重结构、模型配置与 Tokenizer 机制。
2. **高效微调与训练技术**
   - **高效微调（PEFT）**：熟练掌握 LoRA、QLoRA、Freeze 等低秩适应与参数高效微调方法，理解其显存优化逻辑。
   - **分布式与显存控制**：掌握 DeepSpeed、混合精度训练（FP16/BF16）及大模型训练中的显存瓶颈排查。
3. **推理加速与工程部署优化**
   - **模型量化压缩**：掌握 GPTQ、AWQ、BitsAndBytes 等量化技术，学会在平衡显存占用与模型精度之间做取舍。
   - **高性能推理引擎**：熟悉 vLLM、TensorRT-LLM 或 Hugging Face Pipeline 的贪婪解码、异步推理与多线程并发优化。
4. **评估对齐与 RAG 落地**
   - **模型对齐与评测**：了解 RLHF、DPO 等对齐算法，以及如何使用 Benchmark 评估模型性能。
   - **RAG 系统调优**：具备向量检索（如 FAISS、m3e-base）、精细化文本分块（Chunking）及提示词工程调优经验。

你在本项目中实际落地的 **Transformers 本地加载、KV Cache 复用、多线程调度及 PyInstaller 绿色部署封装**，正是企业非常看重的工程落地能力。